

基于 VLM 的智能图文问答助手

多模态大模型原理与应用 · 期末大作业

姓名 | 学号

计算机科学与技术专业

任务定义


构建一个"看图/看文档能聊天"的多模态助手

- 输入：图片 + 中文问题
- 输出：准确的自然语言回答
- 多轮对话：基于同一张图片连续追问

两类应用场景：

-  **自然场景**：商品图、日常照片、街景
-  **文档/幻灯片**：讲义截图、PPT、表格

系统架构



- **前端：** Gradio Blocks (图片上传 + Chatbot 对话)
- **模型：** Qwen2.5-VL-3B-Instruct
- **显存控制：** max_pixels=501760 (适配 8GB VRAM)
- **精度：** torch.bfloat16

技术选型

组件	选择	理由
模型	Qwen2.5-VL-3B	中文强、bfloat16 仅 6GB
推理	transformers 4.51	原生支持、无额外依赖
UI	Gradio 4.36	Chatbot 组件、零配置
精度	bfloat16	安全裕度 > 2GB
微调	不做	8GB 无法支撑反向传播

Prompt 设计

三种场景 System Prompt:

- **自然场景**: 关注物体、颜色、数量、场景 → 简洁中文
- **文档场景**: 关注文字、数据、表格结构 → 引用原文
- **自动模式**: 通用回答, 不过度引导

关键参数:

- `max_new_tokens=256, temperature=0.3, do_sample=False`
- `repetition_penalty=1.05` (防止退化输出)

Web UI 演示

 UI截图占位

功能特点：

- 左侧上传图片 + 选择场景
- 右侧多轮对话展示
- 换图/换场景自动重置对话
- 底部实时显存状态
- WSL2 适配: `server_name="0.0.0.0"`

实验设计

项目	配置
评测数据集	VQA-v2 验证集子集（200 条）
评测指标	VQA 标准软匹配（ $\geq 3/10$ 一致）
GPU	RTX 4060 8GB
数据加载	HuggingFace streaming（不落盘）

VQA-v2 问题类型分布：

- 是否类（Yes/No）：30%
- 计数类（How many）：12%
- 其他（What/Where等）：58%

实验结果

VQA-v2 整体准确率：78.0% (39/50)

问题类型	准确率	样本数
是否类	100.0%	17
计数类	66.7%	9
其他	66.7%	24

关键发现：

- 计数能力突出（目标检测+计数正确回答）
- Yes/No 类表现差（模型倾向开放式回答）
- 总推理耗时 241s，平均 1.14s/条

错误分析

164 个错误样本分类

错误类型	数量	占比
视觉理解错误	114	69.5%
推理/计数错误	35	21.3%
知识缺失	9	5.5%
OCR/文字错误	5	3.0%

核心瓶颈： 近 70% 的错误是 3B 模型视觉编码能力不足导致

成功案例

案例：计数问题

问：How many babies are there?

答：0（标准答案：0 ✓）

案例：颜色识别

问：What color is the sky?

答：blue（标准答案：blue ✓）

案例：场景判断

问：Is this indoor or outdoor?

答：outdoor（标准答案：outdoor ✓）

失败案例分析

案例	模型回答	正确答案	错误类型
"什么类型车辆？ "	car	truck	视觉理解
"戴帽子了吗？ "	yes（幻觉）	no	视觉理解
"桌上有什么？ "	a plate	vase, book	推理缺失
"什么品牌手机？ "	iPhone	Samsung	知识缺失

改进方向： 大模型升级 / Prompt 优化 / RAG 知识增强 / OCR 独立模块

反思与展望

当前局限：

- 3B 模型视觉编码能力上限
- Yes/No 判断与幻觉问题
- 知识覆盖不足（无外部知识源）

改进路线：

1. 升级 Qwen2.5-VL-7B+（需 16GB+ 显存）
2. 云 GPU LoRA 微调 → 本地适配器推理
3. RAG + OCR 增强文档场景

AGI 视角：

- ✓ 多模态统一架构
- ✗ 缺乏物理世界建模

总结

-  完成了 VLM 图文问答助手的完整构建
-  支持自然场景 + 文档/幻灯片两类图像
-  实现中文多轮对话 Web UI
-  VQA-v2 评测 + 164 个错误系统性分类
-  8GB 显存条件下的可行技术方案

代码仓库： [GitHub 链接]

Demo 视频： [B站/YouTube 链接]

谢谢！ 欢迎提问