

基于 **VLM** 的智能图文问答助手

多模态大模型原理与应用 · 期末大作业答辩

23336012 王泓皓 23336016 肖淇 23336006 韩冠东

计算机科学与技术专业 · 计算机学院

任务定义


构建一个"看图/看文档能聊天"的多模态助手

| 要素 | 说明 | |-----|-----| | 输入 | 图片 + 中文自然语言问题 | | 输出 | 准确、简洁的中文回答 | | 对话 | 基于同一张图片的多轮连续追问 | | 场景 | □ 自然场景 + □ 文档/幻灯片 |

核心要求：

- 至少两类图像（自然场景、文档/幻灯片）
- 中文问答与基础推理
- Web UI 或 CLI 交互界面
- 公开数据集定量评测 + 案例分析

系统架构



- 四大核心模块：
- 1. **Gradio Web UI**
 - 图片上传 + 多轮对话
 - 2. **Config & Prompt 管理**
 - 三种场景 System Prompt
 - 3. **Qwen2.5-VL-3B (bfloat16)**
 - 推理引擎，max_pixels=501760
 - 4. **Chat History Manager**
 - 多轮上下文记忆

技术选型与系统实现

| 组件 | 选型 | 关键参数 | |-----|-----|-----| | 模型 | Qwen2.5-VL-3B-Instruct | bfloat16, ~6GB VRAM | | 推理框架 | HuggingFace Transformers 4.51.0 | device_map="auto" |
| 图像处理 | qwen_vl_utils 0.0.8 | min_pixels=200704, max_pixels=501760 | | Web UI | Gradio 6.17.3 | server_name="0.0.0.0" (WSL2适配) | | 生成策略 | greedy
decoding | do_sample=False, repetition_penalty=1.05 |

代码仓库：

github.com/Ceyo04/VLM-QA-Assistant

目录结构：

src/inference/

(模型推理) ·

src/ui/

(Gradio UI) ·

src/eval/

(评测) ·

src/data/

(流式加载) ·

configs/

(配置分离)

推理管线与 Prompt 工程

推理流程（四步）：

步骤	操作	说明	----- ----- -----	1. 图像预处理					
process_vision_info()									
max_pixels=501760	限制分辨率	2. Chat Template							
apply_chat_template()									
Qwen2.5-VL 标准消息格式	3. 模型推理								
model.generate()									
bfloat16, greedy, max_new_tokens=256	4. 答案解码								
batch_decode()									
去除输入 tokens，纯文本输出									

评测专用 Prompt（强制短答案）：

Answer the question using a single word or short phrase. Question: {question}	
配合	
max_new_tokens=20	
+	
do_sample=False`，确保输出为单词/短语而非长句。	


实验设计

| 项目 | 配置 | |-----|-----| | GPU | NVIDIA RTX 4060 (8GB VRAM) | | CPU / RAM | Intel i5-12600KF / 32GB DDR4 | | 环境 | WSL2 (Ubuntu), Python 3.12 | | 评测数据集 | VQA-v2 (50条) · TextVQA (100条) · 自建中文集 (69 QA) | | VQA 评测指标 | 标准软匹配 (标注答案出现 ≥ 3 次且清洗后匹配) | | 自建集指标 | 5 分制人工/自动评分 | | 数据加载 | HuggingFace

`streaming=True`

(不落盘, 防 VHDX 膨胀) |

实验结果 (1) : VQA-v2




问题类型	准确率	样本数	是否类 (Yes/No)
17	100.0%	17	17
计数类 (How many)	66.7%	9	6
其他 (What/Where)	66.7%	24	16
整体	78.0%	50	39

- Yes/No 满分：视觉判断能力可靠，Prompt 策略有效
- 计数 66.7%：3B 模型的固有能力边界

实验结果 (2) : TextVQA + 自建中文集

TextVQA (100条) 指标 数值 ----- ----- 准确率 72.0% 正确数 72/100				自建中文集 (69 QA) 类别 均分 ≥4分比例 ----- ----- ----- 文档/幻灯片 4.40			
侧重图像中文字识别：品牌名、路牌、数字				85.0% 自然场景 3.16 51.0% 总计 3.52 60.9%			
				5 张真实课程幻灯片，20 个中文问题			





数据集 样本数 成绩 核心能力	----- ----- ----- -----	VQA-v2 50
78.0%		
通用视觉问答	TextVQA 100	
72.0%		
图像文字阅读	自建中文集 69 QA	
3.52/5		
中文文档理解		

- 三个数据集覆盖了"自然场景视觉 + 文字阅读 + 中文文档"三个维度
- 文档类真实幻灯片表现突出（85% 高分率），证明 3B 模型具备实用级中文 OCR 能力

错误分析

VQA-v2 剩余 11 个错误分类：

错误类型	数量	占比	推理/计数错误	8	72.7%	视觉理解错误	1	9.1%	知识缺失	1	9.1%	OCR/文字错误	1	9.1%
------	----	----	---------	---	-------	--------	---	------	------	---	------	----------	---	------



核心瓶颈：
72.7% 为推理/计数错误 — 3B 模型在需要精细空间推理和关系判断时能力不足。修复评测管线后，基础视觉识别错误锐减至 9.1%。

案例研究

成功案例：

| 场景 | 问题 | 模型回答 | 结果 | |-----|-----|-----|-----| | VQA | "Are the riders on the bikes?" | no | ✓ 10/10一致 | | TextVQA | "what number is this bus?" | 477 | ✓ OCR精准 | | 自建 | "中文版课本的出版社是什么？" | 电子工业出版社 | ✓ 中文满分 |

失败案例：

| 场景 | 问题 | 模型回答 | 正确答案 | 原因 | |-----|-----|-----|-----|-----| | VQA | "What type of vehicle?" | car | truck | 细粒度分类 | | TextVQA | "number on jersey?" | 28 | 22 | OCR小字误差 | | 自建 | "标注样本数最少？" | 文本分类 | 情感分析 | 图表比较 |

反思与展望

模型局限：

- 3B 视觉编码器参数量瓶颈 — 细粒度识别和空间推理能力不足
- `max_pixels=501760` 限制丢失细节信息（影响 OCR 精度）
- 缺乏外部知识源 — 知识依赖型问题表现弱
- 幻觉问题 — 不确定时倾向给出肯定回答

改进方向：

1. 升配硬件 → Qwen2.5-VL-7B（预期 +10~20pp 准确率） 2. RAG 外部知识检索 → 弥补 3B 知识短板 3. 独立 OCR 模块（PaddleOCR）→ 增强文档场景 4. 云 GPU LoRA 微调 → 本地适配器推理 5. 8-bit 量化探索 → 释放显存给更高分辨率输入

AGI 视角：多模态理解的潜力与瓶颈

潜力 ✓：

- 统一感知与理解 — 多模态统一架构，无需管道式传输
- 零样本泛化 — 超越模式匹配的通用理解能力
- 交互式推理 — 多轮对话中的渐进式细化

瓶颈 ✗：

- 细粒度世界建模缺失 — 不理解物理因果（"推倒杯子会怎样"）
- 符号推理与感知脱节 — 无法进行"感知→计算→推理"链
- 持续学习能力缺失 — 知识截止于预训练时间点
- 可解释性不足 — 缺乏 Chain-of-Thought 推理追溯

结论：

当前 VLM 在感知层面已取得显著进展，但距 AGI 要求的"深度理解与推理"仍有根本性差距。

总结

| ✓ 已完成 | 详情 | |-----|-----| | 多模态问答系统 | Qwen2.5-VL-3B, bfloat16, 8GB 显存 | | Web UI | Gradio 6.x, WSL2 适配, 多轮对话 | | 三数据集评测 | VQA-v2 78% · TextVQA 72% · 自建 3.52/5 | | 错误分析 | 系统性分类 + 可视化 + 典型案例 | | 技术文档 | LaTeX 15页报告 + 8篇引用 + 完整代码 |

| 📄 链接 | 地址 | |-----|-----| | 代码仓库 | github.com/Ceyo04/VLM-QA-Assistant | | Demo 视频 | [B站/YouTube 链接] |

谢谢！欢迎提问